Metody numeryczne
IO/IT, WIMiIP

Danuta Szeliga

AGH Kraków

2025/2026

Spis treści I

1. Metody numeryczne

2. Organizacja zajęć

3. Pojęcia podstawowe
   - Co to są metody numeryczne?
   - Numeryczna reprezentacja liczb
   - Uwarunkowanie zadania
   - Algorytmy numerycznie poprawne
   - Algorytmy numerycznie stabilne

Organizacja zajęć

- Wykłady - 28h
- Ćwiczenia laboratoryjne - 28h
- Kurs na platformie UPeL (materiały do wykładów)

Organizacja zajęć

- Wykłady - 28h
- Ćwiczenia laboratoryjne - 28h
- Kurs na platformie UPeL (materiały do wykładów)
- Zaliczenia i egzaminy:
  platforma UPeL
- Zakres materiału, literatura:
  syllabus AGH

Metoda numeryczna

- Metoda numeryczna
  - Metoda rozwiązania problemu matematycznego poprzez wykonanie operacji na liczbach (rozwiązanie przybliżone)
  - Numeryczna reprezentacja liczb
  - Uwarunkowanie zadania
  - Zmiennopozycyjne działania arytmetyczne
  - Algorytm numerycznie poprawny
  - Algorytm numerycznie stabilny
  - Arytmetyka wyższej prezycji
  - Obliczanie funkcji standardowych
  - Złożoność obliczeniowa
- Rozwiązanie analityczne (rozwiązanie dokładne)

Reprezentacja liczby

- Liczby w maszynie cyfrowej - reprezentowane przez skończoną liczbę cyfr ich rozwinięć pozycyjnych
- Podstawa rozwinięcia - najczęściej cyfra 2, 8, 16
- Liczby całkowite - zapis stałopozycyjny
- Liczby rzeczywiste - zapis zmiennopozycyjny, standard IEEE 754 (William Kahanen)

Liczby całkowite

$$l = s \sum_{i=0}^{n} e_i 2^i \qquad e_n \neq 0 \; dla \; l \neq 0$$

s - znak liczby l $s = +1$ lub -1
$e_i = 0$ lub 1 - cyfry dwójkowe liczby l
Reprezentacja w maszynie cyfrowej - słowo o długości $d + 1$
Jeśli $n < d$, to l jest reprezentowana w rozpatrywanej arytmetyce
Możliwość reprezentacji liczb całkowitych z przedziału $[-2^d + 1, 2^d - 1]$
Przykład
Zapis liczby w systemie dziesiętnym
7582 = 7 x 1000 + 5 x 100 + 8 x 10 + 2 x 1

Wagi	1000 10^3	100 10^2	10 10^1	1 10^0
Cyfry	**7**	**5**	**8**	**2**
pozycje	3	2	1	0

Liczby rzeczywiste

Dowolną liczbę rzeczywistą $x \neq 0$ można przedstawić w postaci

$$x = s\, 2^c m$$

s - znak liczby / $s = +1$ lub -1
c - liczba całkowita zwana *cechą*
m - liczba rzeczywista z przedziału $\left[\frac{1}{2}, 1\right)$ zwana *mantysą*
Jeśli $x \neq 0$, to powyższy zapis jest jednoznaczny

Liczby rzeczywiste

Cecha c jest zapisywana w sposób stałopozycjny na $d - t$ bitach słowa maszyny cyfrowej
t bitów przeznaczonych jest na mantysę m, ale zamiast jej nieskończonego rozwinięcia

$$m = \sum_{i=1}^{\infty} e_{-i} 2^{-i}$$

zapamiętywanych jest tylko t początkowych cyfr dwójkowych.

Liczby rzeczywiste

Zakładamy, że mantysa jest prawidłowo zaokrąglona do t cyfr:

$$m_t = \sum_{i=1}^{t} e_{-i} 2^{-i} + e_{-(t+1)} 2^{-t}$$

Wobec tego

$$|m - m_t| \leqslant \frac{1}{2} 2^{-t}$$

Liczby rzeczywiste

Zakładamy, że mantysa jest prawidłowo zaokrąglona do t cyfr:

$$m_t = \sum_{i=1}^{t} e_{-i} 2^{-i} + e_{-(t+1)} 2^{-t}$$

Wobec tego

$$|m - m_t| \leqslant \frac{1}{2} 2^{-t}$$

Jeżeli przez $rd\,(x)$ oznaczymy reprezentację zmiennopozycyjną liczby x:

$$rd\,(x) = s\, 2^c m_t$$

to błąd reprezentacji liczby $x \neq 0$ jest równy $\left|\frac{rd(x)-x}{x}\right| \leqslant 2^{-t}$ lub równoważnie $rd\,(x) = x\,(1+\varepsilon)\,, |\varepsilon| \leqslant 2^{-t}$

Definicja formatu zmiennoprzecinkowego IEEE 754

Standard IEEE 754
Definiuje dwa rodzaje liczb zmiennoprzecinkowych: 32-bitowe (pojedynczej precyzji (single precision)) oraz 64-bitowe (podwójnej precyzji (double precision)
Kod binarny liczby zmiennoprzecinkowej podzielony jest na trzy pola zawierające komponenty zapisu zmiennoprzecinkowego

Format zapisu zmiennoprzecinkowego IEEE 754			
32 bity - pojedyncza precyzja	(1 bit) $\mathbf{b31}$	(8 bitów) $\mathbf{b30} \ldots \mathbf{b23}$ (BIAS=127)	(23 bity) ,$\mathbf{b22} \ldots \mathbf{b0}$ (U1)
64 bity - podwójna precyzja	(1 bit) $\mathbf{b63}$	(11 bitów) $\mathbf{b62} \ldots \mathbf{b52}$ (BIAS=1023)	(52 bity) ,$\mathbf{b51} \ldots \mathbf{b0}$ (U1)
Opis pół bitowych	bit znaku	bity kodu cechy	bity ułamkowe mantysy

Uwarunkowanie zadania

Zadanie. Oblicz dla danych $\mathrm{d} = (d_1, \ldots, d_n)$ wynik $\mathrm{w} = (w_1, \ldots, w_m)$:

$$\mathrm{w} = \phi(\mathrm{d})$$

gdzie ϕ - odwzorowanie ciągłe $\phi : R_d \longrightarrow R_w$, R_d, R_w - skończenie wymiarowe przestrzenie unormowane z iloczynem kartezjańskim

Szukamy rozwiązania numerycznego dla danych

$$rd(d_1), rd(d_2), \ldots, rd(d_n)$$

gdzie $rd(d_i) = d_i(1 + \varepsilon_i)$, $|\varepsilon_i| \leqslant 2^{-t}$

Pytanie: czy niewielka względna zmiana danych może powodować duże względne zmiany rozwiązania (wyników)?

Uwarunkowanie zadania - przykład 1

Zerami wielomianu (J.H. Wilkinson) $w(x) = a_0 + a_1 x + \ldots + a_{20} x^{20} = \prod_{k=1}^{20} (x - k)$ są liczby naturalne $1, 2, \ldots, 20$.

Uwarunkowanie zadania - przykład 1

Zerami wielomianu (J.H. Wilkinson) $w(x) = a_0 + a_1 x + \ldots + a_{20} x^{20} = \prod_{k=1}^{20} (x - k)$ są liczby naturalne $1, 2, \ldots, 20$.

Zaburzamy jeden ze współczynników, np. $a_{19} = -210$ tak, że $a_{19}(\varepsilon) = -\left(210 + 2^{-23}\right)$ i otrzymujemy $w_\varepsilon(x) = w(x) - 2^{-23} x^{19}$.
Mamy zatem $a_{19}(\varepsilon) = a_{19}(1 - \varepsilon)$, $\varepsilon = \left(2^{23} \cdot 210\right)^{-1} < 2^{-30}$

Uwarunkowanie zadania - przykład 1

Zerami wielomianu (J.H. Wilkinson) $w(x) = a_0 + a_1 x + \ldots + a_{20} x^{20} = \prod_{k=1}^{20} (x - k)$ są liczby naturalne $1, 2, \ldots, 20$.

Zaburzamy jeden ze współczynników, np. $a_{19} = -210$ tak, że $a_{19}(\varepsilon) = -\left(210 + 2^{-23}\right)$ i otrzymujemy $w_\varepsilon(x) = w(x) - 2^{-23} x^{19}$.
Mamy zatem $a_{19}(\varepsilon) = a_{19}(1 - \varepsilon)$, $\varepsilon = \left(2^{23} \cdot 210\right)^{-1} < 2^{-30}$

Okazuje się, że niewielka zmiana względna tylko jednego współczynnika wielomianu powoduje duże zmiany jego zer. Wielomian $w_\varepsilon(x)$ ma pierwstki zespolone (!), np. najbliższymi pierwiastkowi 15 wielomianu $w(x)$ są pierwiastki $13.992358 \pm 2.51883i$

Uwarunkowanie zadania - przykład 2

Zadanie obliczania iloczynu skalarnego

$$S = \sum_{i=1}^{n} a_i b_i \neq 0$$

Zaburzamy dane a $= (a_1, \ldots, a_n)$, b $= (b_1, \ldots, b_n)$, tak, że $a_i^{\alpha} = a_i (1 + \alpha_i)$, $b_i^{\alpha} = b_i (1 + \beta_i)$, $i = 1 \ldots n$. Zakładamy, że α_i i β_i na tyle małe, że ich iloczyny można zaniedbać.

Uwarunkowanie zadania - przykład 2

Szacujemy względną zmianę wyniku:

$$\left| \frac{\sum_{i=1}^{n} a_i \left(1+\alpha_i\right) b_i \left(1+\beta_i\right) - \sum_{i=1}^{n} a_i b_i}{\sum_{i=1}^{n} a_i b_i} \right| \approx \left| \frac{\sum_{i=1}^{n} a_i b_i \left(\alpha_i + \beta_i\right)}{\sum_{i=1}^{n} a_i b_i} \right|$$

$$\leqslant \max_i \left|\alpha_i + \beta_i\right| \frac{\sum_{i=1}^{n} \left|a_i b_i\right|}{\left|\sum_{i=1}^{n} a_i b_i\right|}$$

Uwarunkowanie zadania - przykład 2

Za wskaźnik uwarunkowania można uznać wielkość:

$$cond\,(\mathrm{a},\mathrm{b}) = \sum_{i=1}^{n} |a_i b_i| \Big/ \left| \sum_{i=1}^{n} a_i b_i \right|$$

bo maksymalne zaburzenie względne danych może przenieść się na zaburzenie względne wyniku co najwyżej z takim mnożnikiem.
Gdy wszystkie sumowane $a_i b_i$ są tego samego znaku, to $cond\,(\mathrm{a},\mathrm{b}) = 1$, więc zadanie obliczania iloczynu skalarnego S jest bardzo dobrze uwarunkowane (mało wrażliwe na zaburzenia danych).

Uwarunkowanie zadania

Jeżeli niewielkie względne zmiany danych zadania powodują duże względne zmiany jego rozwiązania, to zadanie nazywamy **zadaniem źle uwarunkowanym**.

Uwarunkowanie zadania jest **cechą samego zadania, niczym nie związaną z metodą jego rozwiązywania**.

Jak rozwiązać ten problem?
Należy przekształcić zadanie wyjściowe do innego, matematycznie równoważnego zadania, które jest dobrze uwarunkowane.

Algorytmy numerycznie poprawne

Pytanie: jak dokładny może być dla danego zadania wynik obliczeniowy w arytmetyce zmiennopozycyjnej?

Za numerycznie najlepsze są uznawane algorytmy, dla których obliczone rozwiązanie jest nieco zaburzonym rozwiązaniem (dokładnym) zadania o nieco zaburzonych danych.
Algorytm spełniający ten postulat jest *numerycznie poprawny*.

Algorytmy numerycznie poprawne

Niech A oznacza algorytm obliczania wyniku $w = \phi(d)$ dla dowolnych danych $d \in D$ (realizacja dokładna).

Niech $fl(A(d))$ będzie realizcją algorytmu A w arytmetyce fl, polegającą na:

- zastąpieniu wielkości liczbowych występujących w A ich reprezentacjami zmiennoprzecinkowymi
- wykonaniu operacji arytmetycznych w arytmetyce fl (na ogół w sposób przybliżony)

Algorytmy numerycznie poprawne

Niech A oznacza algorytm obliczania wyniku $\mathrm{w} = \phi(\mathrm{d})$ dla dowolnych danych $\mathrm{d} \in \mathrm{D}$ (realizacja dokładna).

Niech $fl(A(\mathrm{d}))$ będzie realizcją algorytmu A w arytmetyce fl, polegającą na:

- zastąpieniu wielkości liczbowych występujących w A ich reprezentacjami zmiennoprzecinkowymi
- wykonaniu operacji arytmetycznych w arytmetyce fl (na ogół w sposób przybliżony)

Zakładamy, że dane d i wyniki w są reprezentowane w przestrzeniach R_d i R_w z błędami nie większymi odpowiednio od ρ_d i ρ_w:

$$\|\mathrm{d} - rd(\mathrm{d})\| \leqslant \rho_d \|\mathrm{d}\| \quad \wedge \quad \|\mathrm{w} - rd(\mathrm{w})\| \leqslant \rho_w \|\mathrm{w}\|$$

Stałe ρ_d i ρ_w są niewielkimi krotnościami 2^{-t}.

Algorytmy numerycznie poprawne

Definicja. Algorytm A nazywamy *numerycznie poprawnym* w klasie zadań $\{\phi; D\}$, jeśli istnieją stałe K_d, K_w takie, że dla każdego $\mathrm{d} \in D$, dla dostatecznie silnej arytmetyki, istnieje $\tilde{\mathrm{d}} \in D$ takie, że

$$\begin{aligned} \left\| \mathrm{d} - \tilde{\mathrm{d}} \right\| &\leqslant \rho_d K_d \left\| \mathrm{d} \right\| \\ \left\| \phi\left(\tilde{\mathrm{d}}\right) - fl\left(A\left(\mathrm{d}\right)\right) \right\| &\leqslant \rho_w K_w \left\| \phi\left(\tilde{\mathrm{d}}\right) \right\| \end{aligned}$$

Stałe K_d, K_w to *wskaźniki kumulacji* algorytmu A w klasie zadań $\{\phi; D\}$.
Dla dowolnego zadania wyznaczania elementu $\phi(\mathrm{d})$, rozwiązanie $fl(A(\mathrm{d}))$, obliczone algorytmem numerycznie poprawnym, różni się od rozwiązania dokładnego $\phi(\tilde{\mathrm{d}})$ co najwyżej K_w razy więcej niż poziom błędu jego reprezentacji. Jednocześnie $\phi(\tilde{\mathrm{d}})$ jest dokładnym rozwiązaniem zadania dla danych $\tilde{\mathrm{d}}$ różniących się od danych początkowych d co najwyżej K_d razy więcej niż poziom błędu ich reprezentacji.

Algorytmy numerycznie stabilne

Pytanie: jaki jest poziom błędu rozwiązania spowodowanego zaburzeniem danych i wyniku na poziomie błędu ich reprezentacji?

Algorytmy numerycznie stabilne

Pytanie: jaki jest poziom błędu rozwiązania spowodowanego zaburzeniem danych i wyniku na poziomie błędu ich reprezentacji?

Rozpatrzmy zadanie obliczenia dla danych d wyniku $w = \phi(d)$.
Niech:
$\hat{d}$ - dane zaburzone na poziomie błędu reprezentacji
$\hat{w}$ - rozwiązanie dokładne dla danych $\hat{d}$ zaburzone na poziomie błędu reprezentacji
czyli:

$$\begin{aligned} w &= \phi(d) & \left\| d - \hat{d} \right\| &\leqslant \rho_d \|d\| \\ \hat{w} &= \phi(\hat{d}) & \|\hat{w} - \tilde{w}\| &\leqslant \rho_w \|\hat{w}\| \end{aligned}$$

Algorytmy numerycznie stabilne

Na podstawie rozważań z poprzedniego slajdu otrzymujemy oszacowanie

$$\begin{aligned}\|\mathrm{w}-\tilde{\mathrm{w}}\| &\leqslant \|\mathrm{w}-\hat{\mathrm{w}}\|+\|\hat{\mathrm{w}}-\tilde{\mathrm{w}}\| \\ &\leqslant (1+\rho_w) \max_{\hat{\mathrm{d}}:\left\|\mathrm{d}-\hat{\mathrm{d}}\right\|\leqslant\rho_d\|\mathrm{d}\|} \left\|\phi(\mathrm{d})-\phi(\hat{\mathrm{d}})\right\| + \rho_w \|\mathrm{w}\|\end{aligned}$$

i stąd definiujemy pojęcie optymalnego poziomu błędu rozwiązania $\{\phi; D\}$ w arytmetyce *fl*

$$P(\mathrm{d},\phi) \stackrel{df}{=} \rho_w \|\mathrm{w}\| + \max_{\hat{\mathrm{d}}:\left\|\mathrm{d}-\hat{\mathrm{d}}\right\|\leqslant\rho_d\|\mathrm{d}\|} \left\|\phi(\mathrm{d})-\phi\left(\hat{\mathrm{d}}\right)\right\|$$

Algorytmy numerycznie stabilne

Definicja. Algorytm A jest *numerycznie stabilny* w klasie zadań $\{\phi; D\}$, jeśli istnieje stała K taka, że dla każdego d $\in$ D, dla dostatecznie silnej arytmetyki zachodzi nierówność

$$\|\phi(\mathrm{d}) - fl(A(\mathrm{d}))\| \leqslant K \cdot P(\mathrm{d}, \phi)$$

Mówimy, że algorytm numerycznie stabilny to algorytm, który gwarantuje otrzymanie rozwiązania, dla dowolnego zadania rozważanej klasy, z błędem tego samego rzędu, co optymalny poziom błędu rozwiązania danego zadania. Zakładamy, że wskaźnik stabilności K nie jest zbyt duży. Jego wielkość służy ocenie jakości algorytmu. Im mniejsza jego wartość, tym lepszy algorytm.

Algorytmy numerycznie stabilne

Z definicji stabilności algorytmu, jeśli $w = \phi(d) \neq 0$, można wyprowadzić oszacowanie błędu względnego rozwiązania $fl(A(d))$ obliczonego algorytmem numerycznie stabilnym

$$\frac{\|\phi(d) - fl(A(d)\|}{\|\phi(d)\|} \leqslant K\left(cond(d)\rho_d + \rho_w\right)$$

Uwarunkowanie, poprawność, stabilność

Przykład

Zadanie rozwiązywania układu dwóch równań liniowych $Ax = b$, gdzie A - macierz nieosobliwa

Rozwiązaniem jest wektor $x = A^{-1}b$, ale jako algorytm numeryczny nie jest to rozwiązanie dobre

Nech będą dane: macierz A, wektor b. Zaburzamy tylko prawą stronę, wektor b.

