Metody numeryczne
Układy równań liniowych
IO/IT

Danuta Szeliga

AGH Kraków

2025/2026

Spis treści

1. Definicja zadania
2. Metody dokładne
   - Metoda eliminacji Gaussa
   - Rozkład LU
3. Metody przybliżone
   - Metody stacjonarne rozwiązywania układów równań liniowych
   - Metody projekcji
4. Przykłady
5. Przypomnienie z algebry

Definicja zadania

- Dane jest równanie postaci (zapis wektorowy):

$$\mathbf{Ax} = \mathbf{b} \tag{1}$$

gdzie:
$\mathbf{A}$ macierz $n \times n$
$\mathbf{x}$ szukany wektor o rozmiarze n
$\mathbf{b}$ wektor wyrazów wolnych o rozmiarze n

- Równanie (1) można zapisać także jako:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \ldots a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \ldots a_{2n}x_n &= b_2 \\ \ldots\ldots\ldots & \\ a_{n1}x_1 + a_{n2}x_2 + \ldots a_{nn}x_n &= b_n \end{aligned} \tag{2}$$

Metody dokładne rozwiązywania liniowych układów równań

Metoda eliminacji Gaussa

Metoda eliminacji Gaussa

- Postać macierzowa równania (1)

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n1} & \cdots & a_{nn} \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \\ \cdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \cdots \\ b_n \end{bmatrix} \tag{3}$$

- Do macierzy $\mathbf{A}$ dopisujemy wektor wyrazów wolnych $\mathbf{b}$ - powstaje tzw. macierz rozszerzona

$$\mathbf{A}|\mathbf{b} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & b_n \end{bmatrix} \tag{4}$$

Metoda eliminacji Gaussa

- W kolejnych krokach rozpoczynamy przekształcanie rozszerzonej macierzy $\mathbf{A}|\mathbf{b}$ w macierz trójkątną górną - ten etap nosi nazwę eliminacji

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} - \frac{a_{21}}{a_{11}} a_{11} & a_{22} - \frac{a_{21}}{a_{11}} a_{12} & \cdots & a_{2n} - \frac{a_{21}}{a_{11}} a_{1n} & b_2 - \frac{a_{21}}{a_{11}} b_1 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{n1} - \frac{a_{n1}}{a_{11}} a_{11} & a_{n2} - \frac{a_{n1}}{a_{11}} a_{12} & \cdots & a_{nn} - \frac{a_{n1}}{a_{11}} a_{1n} & b_n - \frac{a_{n1}}{a_{11}} b_1 \end{bmatrix} =$$

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ 0 & a_{22} - \frac{a_{21}}{a_{11}} a_{12} & \cdots & a_{2n} - \frac{a_{21}}{a_{11}} a_{1n} & b_2 - \frac{a_{21}}{a_{11}} b_1 \\ 0 & \cdots & \cdots & \cdots & \cdots \\ 0 & a_{n2} - \frac{a_{n1}}{a_{11}} a_{12} & \cdots & a_{nn} - \frac{a_{n1}}{a_{11}} a_{1n} & b_n - \frac{a_{n1}}{a_{11}} b_1 \end{bmatrix} \tag{5}$$

- Otrzymujemy macierz postaci

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ 0 & a'_{22} & \cdots & a'_{2n} & b'_2 \\ 0 & \cdots & \cdots & \cdots & \cdots \\ 0 & a'_{n2} & \cdots & a'_{nn} & b'_n \end{bmatrix}$$

(6)

$$\begin{aligned} &a_{ii}\colon\ i = 0, n-1 \\ &a_{kj}\colon\ k = i+1, n-1,\ j = 0, n-1 \\ &\qquad a_{kj} = a_{kj} - a_{ki}/a_{ii} \cdot a_{ij} \\ &\qquad b_k = b_k - a_{ki}/a_{ii} \cdot b_i \end{aligned}$$

Metoda eliminacji Gaussa cd.

- Ostatecznie otrzymujemy

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & a'_{22} & a'_{23} & \cdots & a'_{2n} \\ 0 & 0 & a''_{33} & \cdots & a''_{3n} \\ 0 & 0 & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & a_{nn}^{\prime\times(n-1)} \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \cdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b'_2 \\ b''_3 \\ \cdots \\ b_n^{\prime\times(n-1)} \end{bmatrix} \tag{7}$$

- Kolejne składowe x_i znajdujemy rekurencyjnie wg wzorów

$$\begin{aligned} x_n &= \frac{b_n^{\prime\times(n-1)}}{a_{nn}^{\prime\times(n-1)}} \\ x_i &= \frac{b_i^{\prime\times(i-1)} - a_{in}^{\prime\times(i-1)} x_n - \ldots - a_{i\,i+1}^{\prime\times(i-1)} x_{i+1}}{a_{ii}^{\prime\times(i-1)}} \qquad i = n-1, n-2, \ldots, 1 \end{aligned} \tag{8}$$

Eliminacja Gaussa-Crouta

- Algorytm eliminacji Gaussa posiada dosyć istotną wadę
- Bazuje na dzieleniu przez elementy leżące na głównej przekątnej macierzy współczynników
- Może się zdarzyć, że element przekątnej głównej jest równy zero lub zostanie wyzerowany w wyniku obliczeń
- Ulepszeniem algorytmu eliminacji Gaussa jest metoda Crouta
  - na początku eliminacji wyszukujemy w wierszu macierzy $\mathbf{A}$ element o największym module
  - zamieniamy miejscami kolumnę ze znalezionym elementem z kolumną zawierającą element głównej przekątnej
  - w ten sposób dzielnik będzie posiadał największą wartość ze względu na moduł
  - pozbędziemy się sytuacji, gdy może on posiadać wartość 0 (chyba że cały wiersz macierzy $\mathbf{A}|\mathbf{b}$ jest zerowy – ale wtedy równania i tak nie można rozwiązać)

Eliminacja Gaussa-Crouta

- Zmodyfikowany algorytm eliminacji Gaussa wymaga zapamiętania, które kolumny zostały zamienione
  - na etapie wyznaczania niewiadomych musimy znać numery wyliczanych niewiadomych
- Wprowadzamy do algorytmu dodatkowy wektor $\mathbf{w}$ przechowujący informację o numerach kolumn
  - zamiana miejscami kolumn nie wymaga faktycznego ich przemieszczania w pamięci – wystarczy odwoływać się do nich poprzez wektor kolumn
- Jeśli w wektorze $\mathbf{w}$ zamienimy ze sobą numery dwóch kolumn (są to tylko dwa elementy, zatem wymiana jest w czasie stałym), to efekt będzie taki, jakby te kolumny zostały zamienione miejscami w macierzy $\mathbf{A}|\mathbf{b}$

Rozkład $\mathbf{LU}$

Rozkład $\mathbf{LU}$

- Dana jest macierz kwadratowa $\mathbf{A} \in \mathbb{R}^{\mathbf{n}\times\mathbf{n}}$
- Macierz $\mathbf{A}$ można przedstawić w postaci iloczynu macierzy $\mathbf{L} \in \mathbb{R}^{\mathbf{n}\times\mathbf{n}}$ i $\mathbf{U} \in \mathbb{R}^{\mathbf{n}\times\mathbf{n}}$:

$$\mathbf{A} = \mathbf{L} \times \mathbf{U} \tag{9}$$

takich, że:

  - $\mathbf{L}$ jest macierzą trójkątną dolną o elementach na głównej przekątnej równych 1
  - a $\mathbf{U}$ jest macierzą trójkątną górną

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \cdots & a_{3n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{bmatrix} = \mathbf{L} \times \mathbf{U} = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ l_{21} & 1 & 0 & \cdots & 0 \\ l_{31} & l_{32} & 1 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ l_{n1} & l_{n2} & l_{n3} & \cdots & 1 \end{bmatrix} \times \begin{bmatrix} u_{11} & u_{12} & u_{13} & \cdots & u_{1n} \\ 0 & u_{22} & u_{23} & \cdots & u_{2n} \\ 0 & 0 & u_{33} & \cdots & u_{3n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & u_{nn} \end{bmatrix} \tag{10}$$

Wyznaczanie rozkładu $\mathbf{LU}$. Metoda Doolittle'a I

- Z mnożenia macierzy otrzymujemy

$$\begin{aligned} \mathbf{A} &= \mathbf{L} \times \mathbf{U} \\ a_{ij} &= \sum_{k=1}^{n} l_{ik} \times u_{kj} \end{aligned} \tag{11}$$

- Macierze $\mathbf{L}$ i $\mathbf{U}$ są macierzami trójkątnymi $\rightarrow$ część ich elementów jest równa zero
  - Otrzymujemy dwa przypadki, w zależności od indeksów i oraz j
  - Przypadek 1: $i \leq j$, czyli elementy macierzy $\mathbf{A}$: a_{ij} leżą na głównej przekątnej lub ponad nią. W takim przypadku ostatnim, niezerowym elementem w wierszu i-tym macierzy $\mathbf{L}$ jest element l_{ii}
  - Ogólny wzór (11) redukuje się do postaci

$$a_{ij} = \sum_{k=1}^{i} l_{ik} \times u_{kj} \tag{12}$$

Wyznaczanie rozkładu $\mathbf{LU}$. Metoda Doolittle'a II

- Dodatkowo z postaci macierzy $\mathbf{L}$ wiemy, że element l_{ii}, leżący na głównej przekątnej, jest zawsze równy 1, stąd

$$a_{ij} = \sum_{k=1}^{i-1} l_{ik} \times u_{kj} + u_{ij} \tag{13}$$

- Można zatem wyliczyć element u_{ij}, o ile są znane poprzednie elementy macierzy $\mathbf{L}$ i $\mathbf{U}$

$$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} \times u_{kj} \tag{14}$$

- Przypadek 2: $i > j$, czyli elementy macierzy $\mathbf{A}$: a_{ij} leżą pod główną przekątną.W tym przypadku ostatnim, niezerowym elementem w j-tej kolumnie macierzy $\mathbf{U}$ jest u_{jj}
- Wzór ogóny (11) redukuje się do postaci

$$\begin{aligned} a_{ij} &= \sum_{k=1}^{j} l_{ik} \times u_{kj} \\ a_{ij} &= \sum_{k=1}^{j-1} l_{ik} \times u_{kj} + l_{ij} \times u_{jj} \end{aligned} \tag{15}$$

Wyznaczanie rozkładu $\mathbf{LU}$. Metoda Doolittle'a III

- Otrzymany wzór (16) pozwala wyliczyć elementy l_{ij}, o ile znane są poprzednie elementy macierzy $\mathbf{L}$ i $\mathbf{U}$

$$l_{ij} = \frac{1}{u_{jj}} \times (a_{ij} - \sum_{k=1}^{j-1} l_{ik} \times u_{kj}) \tag{16}$$

Wyznaczanie rozkładu $\mathbf{LU}$. Algorytm Doolittle'a

- W ten sposób otrzymaliśmy algorytmu Doolittle'a wyznaczania rozkładu macierzy $\mathbf{A}$ na iloczyn dwóch macierzy $\mathbf{L}$ i $\mathbf{U}$
- Kolejne kroki algorytmu
  - Utwórz dwie macierze $\mathbf{L}$ i $\mathbf{U}$ o stopniu macierzy $\mathbf{A}$
  - Macierze $\mathbf{L}$ i $\mathbf{U}$ wyzeruj
  - W macierzy $\mathbf{L}$ elementom na głównej przekątnej przypisz wartość 1
  - Dla $j = 1, 2, \ldots, n$ wykonuj
    - ★ Dla $i = 1, 2, \ldots, j$ wykorzystaj równanie (14) do wyznaczenia elementów u_{ij}
    - ★ Dla $i = j+1, j+2, \ldots, n$ wykorzystaj równanie (16) do wyznaczenia elementów l_{ij}

$$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} \times u_{kj}$$

$$l_{ij} = \frac{1}{u_{jj}} \times (a_{ij} - \sum_{k=1}^{j-1} l_{ik} \times u_{kj})$$

Rozkład $\mathbf{LU}$. Przykład I

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \mathbf{L} \times \mathbf{U} = \begin{bmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{bmatrix} \times \begin{bmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{bmatrix}$$

j=1

dla $i = 1$, $j = 1$ wyznaczamy u_{11}:

$$u_{11} = a_{11} - \sum_{k=1}^{0} l_{1k} \times u_{k1} = a_{11}$$

dla $i = 2$, $i > j$, wyznaczamy l_{21}:

$$l_{21} = \frac{1}{u_{11}} \times (a_{21} - \sum_{k=1}^{0} l_{2k} \times u_{k1}) = \frac{1}{u_{11}} \times a_{21}$$

Rozkład $\mathbf{LU}$. Przykład II

dla $i = 3$, $i > j$, wyznaczamy l_{31}:

$$l_{31} = \frac{1}{u_{11}} \times (a_{31} - \sum_{k=1}^{0} l_{3k} \times u_{k1}) = \frac{1}{u_{11}} \times a_{31}$$

Rozkład $\mathbf{LU}$. Przykład III

j=2

dla $i = 1$, $i < j$ wyznaczamy u_{12}:

$$u_{12} = a_{12} - \sum_{k=1}^{0} l_{1k} \times u_{k2} = a_{12}$$

dla $i = 2$, $i = j$, wyznaczamy u_{22}:

$$u_{22} = a_{22} - \sum_{k=1}^{1} l_{2k} \times u_{k2} = a_{22} - l_{21} \times u_{12}$$

dla $i = 3$, $i > j$, wyznaczamy l_{32}:

$$l_{32} = \frac{1}{u_{22}} \times (a_{32} - \sum_{k=1}^{1} l_{3k} \times u_{k2}) = \frac{1}{u_{22}} \times (a_{32} - l_{31} \times u_{12})$$

Rozkład $\mathbf{LU}$. Przykład IV

j=3

dla $i = 1$, $i < j$ wyznaczamy u_{13}:

$$u_{13} = a_{13} - \sum_{k=1}^{0} l_{1k} \times u_{k3} = a_{13}$$

dla $i = 2$, $i < j$, wyznaczamy u_{23}:

$$u_{23} = a_{23} - \sum_{k=1}^{1} l_{2k} \times u_{k3} = a_{23} - l_{21} \times u_{13}$$

dla $i = 3$, $i = j$, wyznaczamy u_{33}:

$$u_{32} = a_{33} - \sum_{k=1}^{2} l_{3k} \times u_{k3} = a_{33} - l_{31} \times u_{13} - l_{32} \times u_{23}$$

Rozkład $\mathbf{LU}$. Przykład V

- Dla przykładowych danych

$$\begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 3 & 2 & 1 \end{bmatrix} \times \begin{bmatrix} 1 & 4 & 7 \\ 0 & -3 & -6 \\ 0 & 0 & 0 \end{bmatrix}$$

Rozkład $\mathbf{LU}$. Algorytm Doolittle'a. Uwagi I

- Potrzebne w równaniach (14) i (16) elementy macierzy $\mathbf{L}$ i $\mathbf{U}$ są zawsze wyliczane wcześniej
- We wszystkich równaniach elementy macierzy $\mathbf{A}$ są używane tylko jeden raz
- Wniosek:
  - Macierze $\mathbf{L}$ i $\mathbf{U}$ mogą zostać umieszczone w miejscu macierzy $\mathbf{A}$ (operacja będzie wykonana *in situ*) i zaoszczędzimy pamięć
  - W macierzy $\mathbf{L}$ istotna jest tylko część leżąca pod główną przekątną. Elementy przekątnej są zawsze równe 1, a elementy leżące nad przekątną są równe zero i nie musimy ich wcale zapamiętywać
  - W macierzy $\mathbf{U}$ istotna staje się tylko główna przekątna oraz elementy leżące nad nią, pozostałe elementy są równe zero i również nie musimy ich zapamiętywać
  - Algorytm Doolittle'a może przekształcać macierz $\mathbf{A}$ w połączone macierze $\mathbf{L}$ i $\mathbf{U}$:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \cdots & a_{3n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} u_{11} & u_{12} & u_{13} & \cdots & u_{1n} \\ l_{21} & u_{22} & u_{23} & \cdots & u_{2n} \\ l_{31} & l_{32} & u_{33} & \cdots & u_{3n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ l_{n1} & l_{n2} & l_{n3} & \cdots & u_{nn} \end{bmatrix}$$

Rozkład $\mathbf{LU}$. Algorytm Doolittle'a. Uwagi II

- Metoda nie jest niezawodna
  - $\rightarrow$ może wystąpić dzielenie przez zero
  - modyfikacja metody $\rightarrow$ algorytm Doolittle-Crout'a
    - zasada podobna jak w przypadku modyfikacji metody eliminacji Gaussa
    - w danym wierszu wybierany jest element o największej wartości modułu i zamieniany z elementem na przekątnej

Rozwiązanie z zastosowaniem $\mathbf{LU}$

- Problem: znaleźć rozwiązanie układu równań liniowych postaci:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \ldots a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \ldots a_{2n}x_n &= b_2 \\ \ldots\ldots\ldots & \\ a_{n1}x_1 + a_{n2}x_2 + \ldots a_{nn}x_n &= b_n \end{aligned}$$

  wykorzystując rozkład $\mathbf{LU}$
- Postać macierzowa zadania:

$$\mathbf{A} \times \mathbf{x} = \mathbf{b}$$

  - Rozkładamy macierz $\mathbf{A}$ na $\mathbf{L}$ i $\mathbf{U}$

$$\mathbf{A} = \mathbf{L} \times \mathbf{U}$$

  - Przekształcamy

$$\begin{aligned} &\mathbf{A} \times \mathbf{x} = \mathbf{b} \\ &(\mathbf{L} \times \mathbf{U}) \times \mathbf{x} = \mathbf{b} \\ &\mathbf{L} \times (\mathbf{U} \times \mathbf{x}) = \mathbf{b} \end{aligned}$$

  - Obliczamy wektor $\mathbf{y}$

$$\mathbf{L} \times \mathbf{y} = \mathbf{b}$$

  - A następnie mając $\mathbf{y}$ obliczamy wektor $\mathbf{x}$, który jest rozwiązaniem układu równań

$$\mathbf{U} \times \mathbf{x} = \mathbf{y}$$

Rozwiązanie z zastosowaniem $\mathbf{LU}$ - cd

- Macierze $\mathbf{L}$ i $\mathbf{U}$, ze względu na swoją postać, pozwalają na bardzo proste wyliczenie $\mathbf{y}$ i $\mathbf{x}$
  - podstawiając w przód

$$y_1 = b_1$$
$$y_i = b_i - \sum_{j=1}^{i-1} l_{ij} y_j \quad i = 2, 3, \ldots n$$

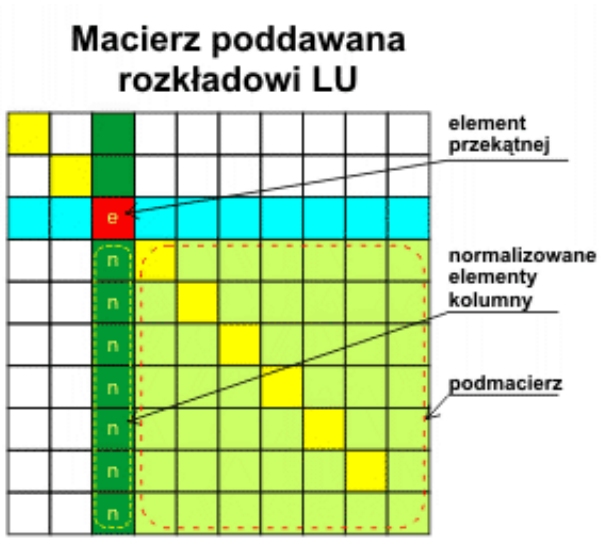
  - podstawiając wstecz

$$x_n = \frac{y_n}{u_{nn}}$$
$$x_i = \frac{1}{u_{ii}} (y_i - \sum_{j=i+1}^{n} u_{ij} x_j) \quad i = n-1, n-2, \ldots 1$$

- Wektor pomocniczy $\mathbf{y}$ może być w pamięci komputera przechowywany w wektorze $\mathbf{x}$ (oszczędność miejsca)
- Takie podejście szczególnie jest przydatne w przypadku konieczności rozwiązywania wielu układów równań, które różnią się jedynie wektorem wyrazów wolnych $\mathbf{b}$
  - W takim przypadku dokonujemy jednokrotnie rozkładu $\mathbf{LU}$ macierzy współczynników $\mathbf{A}$, a następnie, wymieniając jedynie wektor $\mathbf{b}$, rozwiązujemy kolejne układy przy pomocy wyliczonych wcześniej macierzy $\mathbf{L}$ i $\mathbf{U}$

Rozkład LU. Algorytm Crouta

- Przejdź przez kolejne elementy głównej przekątnej macierzy $\mathbf{A}$ od pierwszego do przedostatniego i dla każdego elementu $\mathbf{A}[k,k]$ wykonaj kolejno dwie operacje:
  1. Normalizuj kolumny: elementy w kolumnie pod elementem $\mathbf{A}[k,k]$ są dzielone przez ten element.
  2. Modyfikuj podmacierz, która zawiera wszystkie elementy macierzy $\mathbf{A}$ leżące poniżej i na prawo elementu przekątnej z pominięciem wiersza i kolumny zawierającego element przekątnej.
     - ★ Modyfikacja polega na odjęciu od każdego elementu $\mathbf{A}[i.j]$ tej podmacierzy iloczynu elementów $\mathbf{A}[i,k] \times \mathbf{A}[k,j]$.



- Dzięki takiemu podejściu algorytm rozkładu LU znacznie się upraszcza.

Metody przybliżone
Duże układy równań liniowych

Definicja zadania

- Dane jest równanie postaci (zapis wektorowy):

$$Ax = b \tag{17}$$

gdzie:
A macierz $n \times n$ nieosobliwa
x szukany wektor o rozmiarze n
b wektor wyrazów wolnych o rozmiarze n

- W odróżnieniu od ogólnego zagadnienia rozwiązywania układu równań liniowych, rozpatrujemy układy równań powstałe z dyskretyzacji równania różniczkowego metodami elementu skończonego lub różnic skończonych
- W takm rozwiązaniu macierz A jest bardzo duża, ale zawiera tylko ok. 10% niezerowych elementów (otrzymujemy macierz rozrzedzoną (rzadką))

Problemy

- Używanie bezpośrednich metod rozwiązywania układów równań liniowych
  - Mało efektywne, ponieważ podczas szukania rozkładu macierzy na macierz dolno- i górnotrójkątną następuje utrata wyzerowanych miejsc
  - Przy dużych rozmiarach macierzy wypełnienie wyzerowanych miejsc spowodowałoby znaczne zwiększenie potrzebnej pamięci
- Przykład: dla kilka milionów niewiadomych i dowolnej macierzy (bez żadnej specjalnej struktury), korzystając z eliminacji Gaussa musielibyśmy wykonać rzędu 10^{19} działań arytmetycznych i zarezerwować rzędu 10^{13} bajtów, czyli 10000 GB, pamięci na czynniki rozkładu
  - Przy założeniu, że komputer jest w stanie wykonać 10^{10} działań na sekundę, tzn., że jest w stanie osiągnąć wydajność 10 Gflopów/s, dawałoby to 10^9 sekund, czyli około 32 lat.
  - Stąd alternatywą jest rozwiązanie układu w sposób przybliżony, znacznie tańszy i wygodniejszy
- Do rozwiązywania tego typu zagadnień stosuje się metody iteracyjne, szczególnie użyteczne dla macierzy rozrzedzonych/rzadkich:
  - metody stacjonarne rozwiązywania układów równań liniowych
  - metody projekcji
  - metody Kryłowa

Macierze rozrzedzone/rzadkie

- Okazuje się, że praktyczne zadania liniowe wielkiego wymiaru sprowadzają się do macierzy rozrzedzonej
  - Związki pomiędzy niewiadomymi w pojedynczym równaniu zadanego układu dotyczą jedynie wybranej (nielicznej) grupy innych niewiadomych.
- Wykorzystanie rozrzedzenia macierzy pozwala na zastosowanie algorytmów istotnie szybszych od metod dokładnych dla macierzy gęstych, a w wielu przypadkach jest jedynym sposobem rozwiązania zadania biorąc pod uwagę obecne moce obliczeniowe
  - Przypomnienie: standardowe algorytmy oparte na rozkładzie macierzy gęstej, np. LU, potrzebują $O(N^3)$ działań arytmetycznych
- Gdy macierz A jest rozrzedzona, mnożenie takiej macierzy przez wektor jest bardzo tanie (koszt jest proporcjonalny do liczby niezerowych elementów macierzy)
  - Stąd konstruując metodę przybliżonego rozwiązywania układu opieramy się na iteracjach, których głównym składnikiem jest operacja mnożenia przez A lub jej część

Macierze rozrzedzone. Przykłady I

- Gdzie spotykamy macierze wymiaru N z $O(N)$ liczbą niezerowych elementów?
  - Dyskretyzacja równań różniczkowych
  - Łańcuchy Markowa z dyskretną przestrzenią stanów
- Przykład 1. Eliptyczne równanie różniczkowe z jednorodnym warunkiem brzegowym Dirichleta

$$\begin{aligned} -u''(x) &= f(x) \quad \forall x \in (0,1) \\ u(0) &= u(1) = 0 \end{aligned} \tag{18}$$

  - Szukamy rozwiązania u, f jest znaną funkcją
  - Przybliżone rozwiązanie można otrzymać zastąpując równanie różniczkowe odpowiednim równaniem różnicowym

$$\begin{aligned} -\frac{u_{i-1}-2u_i+u_{i+1}}{h^2} &= f(x_i) \quad \forall i = 1, \ldots, N \\ u_0 &= u_{N+1} = 0 \end{aligned} \tag{19}$$

gdzie u_i odpowiada wartości rozwiązania w węźle dyskretyzacji x_i, $u_i \approx u(x_i)$, oraz $x_i = i \cdot h$ oraz $h = 1/(N+1)$

Macierze rozrzedzone. Przykłady II

- Równanie (19) jest równaniem liniowym ze względu na współczynniki $U_N = (u_1, \ldots, u_N)^T$:

$$T_N U_N = h^2 F_N$$

gdzie

$$T_N = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix}_{N \times N} \tag{20}$$

oraz $F_N = (f(x_1), \ldots, f(x_N))^T$

- Dobre rozwiązanie otrzymamy, gdy h będzie bardzo małe, a to oznacza, że N będzie bardzo duże
- Powstała macierz jest macierzą rozrzedzoną, ma nieco mniej niż $3N$ niezerowych elementów. Współczynnik wypełnienia (stosunek liczby niezerowych do liczby wszystkich elementów macierzy), jest rzędu $3/N$ i maleje ze wzrostem N
- Otrzymana macierz jest jednak zbyt trywialna i można zastosować dla niej metodę eliminacja Gaussa uwzględniając jej pasmową strukturę

Macierze rozrzedzone. Przykłady III

- Ponieważ jest to macierz trójdiagonalna, a przy tym symetryczna i dodatnio określona, to odpowiednio zrealizowany algorytm eliminacji Gaussa lub, lepiej, rozkładu LDL^T, pozwoli wyznaczyć rozwiązanie układu $T_N U_N = h^2 F_N$ kosztem $O(N)$, czyli optymalnym z dokładnością do stałej

- Gdy przejdziemy do wyższych wymiarów, a regularną siatkę węzłów dyskretyzacji zastąpimy nieregularną siatką elementu skończonego, uzyskamy macierze o znacznie bardziej skomplikowanej strukturze, dla których już nie jest tak prosto zastosować metodę eliminacji Gaussa
- Przykład 2. Wielowymiarowy Laplasjan
  - Rozważmy to samo równanie Poissona, ale w obszarze $\Omega \subset \mathbb{R}^d$, z jednorodnym warunkiem Dirichleta postaci:

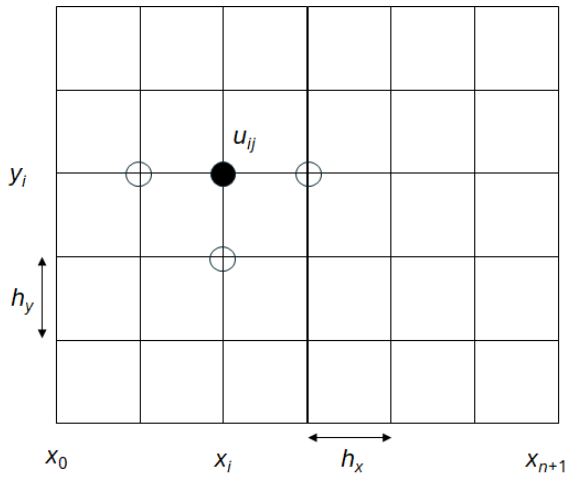
$$\begin{aligned} &\Delta u(x) = f(x) \qquad \forall x \in \Omega, \\ &u_{|\partial\Omega} = 0 \end{aligned} \tag{21}$$

  - Szukamy rozwiązania $u : \Omega \to \mathbb{R}$, $f : \Omega \to \mathbb{R}$ jest zadaną funkcją. Δ jest operatorem Laplace'a:

$$\Delta := \frac{\partial^2}{\partial x_1^2} + \cdots + \frac{\partial^2}{\partial x_d^2}$$

Macierze rozrzedzone. Przykłady IV

- Dla uproszczenia przyjmijmy, że Δ jest jednostkową kostką: $\Delta = (0,1)^d$
- Znalezienie przybliżonego rozwiązania wymaga zastąpienia równania różniczkowego odpowiadającym mu równaniem różnicowym
- Dla schematu różnicowego możemy wybrać najprostszą metodę dyskretyzacji, opartą na równomiernej siatce węzłów w Ω. Jednocześnie metoda ta jest najmniej efektywna
- Przykład. Jeśli $d = 2$, to bierzemy siatkę węzłów $p_{ij} = (x_i, y_i) \in \Omega$, gdzie: $x_i = ih_x$, $y_j = jh_y$, oraz $h_x = a/(n_x + 1)$ jest krokiem siatki w kierunku x, a $h_y = b/(n_y + 1)$ jest krokiem siatki w kierunku y



Regularna siatka na Ω

Macierze rozrzedzone. Przykłady V

- Zastępujemy pochodne ilorazami różnicowymi

$$\Delta u(x_i, y_j) \approx \Delta_h u_{ij} = \frac{1}{h^2}(4u_{i,j} - u_{i+1,j} - u_{i-1,j} - u_{i,j+1} - u_{i,j-1}) \quad (22)$$

- I dostajemy równanie różnicowe

$$-\frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h_x^2} - \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{h_y^2} = f_{ij} \quad (23)$$

$$\forall i = 1, \ldots, n_x,\ j = 1, \ldots, n_y$$

- W pozostałych węzłach siatki rozwiązanie przyjmuje wartość równą zero na podstawie warunku brzegowego Dirichleta.
- Dla uproszczenia zapisu przyjmijmy, że $n_x = n_y = n$ i w konsekwencji $h_x = h_y = h$. W takim układzie mamy do wyznaczenia $N = n^2$ niewiadomych:

$$U_N = (\underbrace{u_{1,1}, u_{2,1}, u_{3,1}, \ldots, u_{n_x,1}}_{\text{niewiadome pierwszej kolumny}}, \underbrace{u_{1,2}, u_{2,2}, u_{3,2}, \ldots, u_{n_x,2}}_{\text{drugiej kolumny}}, \ldots, \underbrace{u_{1,n_y}, u_{2,n_y}, u_{3,n_y}, \ldots, u_{n_x,n_y}}_{\text{ostatniej kolumny}})^T$$

- które spełniają liniowy układ równań o postaci macierzowej

$$P_N U_N = h^2 F_N \quad (24)$$

Macierze rozrzedzone. Przykłady VI

- Macierz P_N jest pięciodiagonalną macierzą o blokowej strukturze:

$$P_N = \begin{pmatrix} T_n + 2I & -I & & & \\ -I & T_n + 2I & -I & & \\ \vdots & \vdots & \vdots & 0 & \\ & & -I & T_n + 2I & -I \\ & & & -I & T_n + 2I \end{pmatrix}_{N \times N} \tag{25}$$

- W kolejnych diagonalnych blokach P_N znajdują się macierze trójdiagonalne $T_n + 2I$, gdzie T_n jest znaną macierzą dyskretyzacji jednowymiarowego laplasjanu
- Używając symbolu Kroneckera dla iloczynu tensorowego macierzy, otrzymujemy przy zachowaniu naszej numeracji niewiadomych

$$P_N = I \otimes T_n + T_n \otimes I$$

- W przypadku macierzy P_N, prosta strategia polegająca na eliminacji Gaussa (z wykorzystaniem dodatkowo faktu, że P_N jest pasmowa, o szerokości pasma $2n$), dałaby szansę na rozwiązanie tego równania kosztem $O(n^4)$, co jest, przy dużych wielkościach n, wartością trudną do zaakceptowania.

Dygresja. Iloczyn tensorowy macierzy (iloczyn Kroneckera)

Iloczynem Kroneckera (iloczynem tensorowym) macierzy $A \in M_{m\times n}$ i macierzy $B \in M_{k\times l}$ nazywa się macierz o wymiarze $mk \times nl$ postaci:

$$A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \cdots \\ a_{21}B & a_{22}B & \\ \vdots & & \ddots \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} & a_{11}b_{12} & \cdots & a_{12}b_{11} & a_{12}b_{12} & \cdots \\ a_{11}b_{21} & a_{11}b_{22} & & a_{12}b_{21} & a_{12}b_{22} & \\ \vdots & & \ddots & & & \\ a_{21}b_{11} & a_{21}b_{12} & & & & \\ a_{21}b_{21} & a_{21}b_{22} & & & & \\ \vdots & & & & & \end{bmatrix}.$$

Metody stacjonarne rozwiązywania układów równań liniowych

Klasyczne metody iteracyjne

- Definiujemy rozkład macierzy $A = M - Z$, gdzie M jest *macierzą łatwo odwracalną*, $Z = A - M$ jest *resztą*.
- Układ $Ax = b$ można zapisać jako zadanie punktu stałego:

$$Mx = Zx + b \tag{26}$$

i jeśli M jest nieosobliwa, to otrzymujemy równoważnie:

$$x = M^{-1}(Zx + b) \tag{27}$$

- Ponieważ problem (26) jest zadaniem znajdowania punktu stałego postaci $x = \Phi(x)$, możemy zastosować metodę iteracji prostej Banacha:

$$x_{k+1} = M^{-1}(Zx_k + b) \tag{28}$$

  - Macierz M powinna być dobrym przybliżeniem macierzy A, co zapewni szybką zbieżność, i łatwo odwracalną.
- Takie metody nazywamy ***stacjonarnymi metodami iteracyjnymi***.

Metody stacjonarne I

- Metody stacjonarne można zapisać w ogólnej postaci

$$x_{k+1} = Bx_k + c \tag{29}$$

gdzie macierz B i wektor c są tak dobrane, żeby punkt stały x^* równania (29) był rozwiązaniem równania wyjściowego $Ax = b$.

- Dla stacjonarnej metody iteracyjnej:

$$B = M^{-1}Z = I - M^{-1}A \quad i \quad c = M^{-1}b$$

Macierz B nazywamy ***macierzą iteracji***, ponieważ zachodzi:

$$x_{k+1} - x^* = B(x_k - x^*) = \ldots = B^{k+1}(x_0 - x^*)$$

Metody stacjonarne II

- Zatem z twierdzenia Banacha o punkcie stałym wynika warunek zbieżności:
  - **Twierdzenie. Warunek wystarczający zbieżności metody stacjonarnej** Jeżeli $\|B\| < 1$, to metoda (29) jest zbieżna co najmniej liniowo do x^* dla dowolnego $x_0 \in R^n$
    - ★ Symbol $\|\cdot\|$ oznacza dowolną normę macierzową indukowaną przez normę wektorową.
  - Wniosek
    - ★ Jeśli $\|I - M^{-1}A\| < 1$, to ciąg określony przez stacjonarną metodę iteracyjną jest zbieżny do $x^* = A^{-1}b$ oraz

$$\|x_{k+1} - x^*\| \leq \|I - M^{-1}A\|\|x_k - x^*\|$$

  - **Twierdzenie. Warunek konieczny i wystarczający zbieżności metody stacjonarnej**
    Niech $B = I - M^{-1}A$ będzie macierzą iteracji metody (29). Ciąg x_k określony tą metodą jest zbieżny do rozwiązania x^* dla dowolnego $x_0 \in R^n$ wtedy i tylko wtedy, gdy:

$$\rho(B) = \max\{|\lambda| : \lambda \text{ jest wartością własną } B\} < 1$$

Klasyczne metody iteracyjne I

- Zaletą stacjonarnych metod iteracyjnych jest ich prostota $\rightarrow$ dają się szybko zaprogramować
- Przykłady klasycznych metod iteracyjnych:
  - Metoda Jacobiego
  - Metoda Gaussa-Seidela
  - Metoda SOR
- Wszystkie metody bazują na podziale macierzy A na trzy części: diagonalną, ściśle dolną trójkątną i ściśle górną trójkątną:

$$A = L + D + U$$

gdzie

$$L = \begin{pmatrix} 0 & & & & \\ a_{21} & 0 & & & \\ a_{31} & a_{32} & 0 & & \\ \vdots & \vdots & & 0 & \\ a_{n1} & a_{n2} & \dots & \dots & 0 \end{pmatrix}, \quad D = \begin{pmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & a_{nn} \end{pmatrix}, \quad U = \begin{pmatrix} 0 & a_{12} & a_{13} & \dots & a_{1n} \\ & 0 & a_{23} & \dots & a_{2n} \\ & & 0 & \ddots & \\ & & & 0 & \\ & & & & 0 \end{pmatrix}$$

Metoda Jacobiego I

- W równaniu (28) przyjmujemy

$$M = D$$

gdzie D jest macierzą diagonalną składającą się z wyrazów stojących na głównej przekątnej macierzy A

- Otrzymujemy, o ile na przekątnej macierzy A nie ma zer, metodę iteracyjną postaci:

$$x_{k+1} = D^{-1}(b - (L + U)x_k) \tag{30}$$

zwaną ***metodą Jacobiego***.

- Schemat (30) można rozpisać dla każdej współrzędnej otrzymując:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right) \tag{31}$$

- Schemat (31) jest
  - prosty w implementacji,
  - implementacja jest w pełni równoległa: każdą współrzędną nowej iteracji można wyznaczyć niezależnie od pozostałych.

Metoda Jacobiego II

- **Twierdzenie. Zbieżność metody Jacobiego**

  W metodzie Jacobiego warunek dostateczny zbieżności, $\|D^{-1}(L+U)\|_\infty < 1$, jest spełniony wtedy, gdy np. macierz A ma dominującą przekątną, tzn. gdy

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \qquad \forall i = 1, \ldots, n$$

- W wielu wypadkach metoda Jacobiego, choć zbieżna, jest zbieżna zbyt wolno.

Metoda Jacobiego. Przykład I

- Przykład: - wolna zbieżność metody Jacobiego
- Rozpatrzmy macierz $n \times n$, zwaną macierzą jednowymiarowego laplasjanu, postaci:

$$T_n = \begin{pmatrix} 2 & -1 & & \\ -1 & 2 & \ddots & \\ & \ddots & \ddots & -1 \\ & & -1 & 2 \end{pmatrix}$$

  - Macierz T_n pojawia się w wielu zastosowaniach, może też być sztucznie wprowadzanym podzadaniem w niektórych algorytmach numerycznych.
  - Ta macierz jest macierzą taśmową, symetryczną i dodatnio określoną, więc układ równań z tą macierzą można bez trudu rozwiązać metodami bezpośrednimi, kosztem $\mathcal{O}(n)$.
  - Ale układ równań z macierzą T_n jest wyjątkowo "trudny" dla klasycznej metody stacjonarnej.
- Stosując do T_n metodę Jacobiego otrzymujemy: $M = 2I$ i $Z = T_n - M$.
- Obliczmy normę macierzy iteracji Jacobiego $M^{-1}Z$: $\|M^{-1}Z\|_\infty = 1$

Metoda Jacobiego. Przykład II

- Mając na uwadze twierdzenie (40), wartość normy 1 nie rozstrzyga jeszcze o zbieżności lub niezbieżności metody, ale trzeba mieć na uwadze potencjalne problemy związane z obliczeniami.
- Analizując dalej: weźmy pod uwagę wartości własne λ_j macierzy T_n, które są znane i są równe:

$$\lambda_j = 2\left(1 - \cos\left(\frac{j\pi}{n+1}\right)\right) = 4\sin^2\left(\frac{j\pi}{2(n+1)}\right)$$

  z czego wynika, że $0 < \lambda_j < 4)$ dla $j = 1 \ldots n$.
- A stąd wartości własne $M^{-1}Z = \frac{1}{2}Z = \frac{1}{2}T_n - I$ są równe $\mu_i = \frac{1}{2}\lambda_i - 1$.
- Ponieważ $-1 < \mu_i < 1$, to metoda Jacobiego jest zbieżna dla macierzy T_n.

Metoda Jacobiego. Przykład III

- Jak szybko zbiega metoda dla macierzy T_n?
- Na podstawie wartości własnych macierzy T_n można wyliczyć wartości własne macierzy $M^{-1}Z$:

$$\rho(M^{-1}Z) = \cos(\pi/(n+1)) = 1 - \frac{\pi^2}{2(n+1)^2} + \mathcal{O}(n^{-4})$$

z czego wynika, że metoda Jacobiego, choć zbieżna, dla dużych n jest zbyt wolno zbieżna, by mogła być stosowana.

  - Na przykład, jeśli $n = 100$, to $\rho(M^{-1}Z) \approx 0.9995$, zatem potrzebowalibyśmy około 4600 iteracji, by mieć pewność, że początkowy błąd zredukowaliśmy zaledwie 10 razy (!).

Metoda Gaussa-Seidela I

- Modyfikacja metody Jacobiego
- Wykorzystuje heurystykę, tzn. w trakcie każdej iteracji bierze najbardziej "aktualne" wartości przybliżenia rozwiązania x.
- Patrząc na schemat iteracyjny metody Jacobiego, w jednym kroku rozwiązujemy równania skalarne względem $x_i^{(k+1)}$ dla $i = 1, \ldots, N$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right) \tag{32}$$

Zauważmy, że w części sumy (32), dla $j < i$, można użyć zamiast "starych" $x_j^{(k)}$ użyć dokładniejszych, "nowych" wartości $x_j^{(k+1)}$ i w ten sposób wyznaczać $x_i^{(k+1)}$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij} x_j^{(k+1)} - \sum_{j>i} a_{ij} x_j^{(k)} \right). \tag{33}$$

Metoda Gaussa-Seidela II

- W zapisie macierzowym dostajemy:

$$A = M - Z \quad \texttt{i iteracji} \quad x_{k+1} = M^{-1}(Zx_k + b)$$

mamy $M = L + D$ (część trójkątną dolną z diagonalą macierzy A) oraz $Z = -U$ (część ściśle trójkątną górną macierzy A)

- I stąd iteracja w zapisie macierzowym jest postaci:

$$x_{k+1} = (L + D)^{-1}(b - Ux_k)$$

- Inny wariant tej metody otrzymuje się biorąc za macierz M część trójkątną górną macierzy A.

- **Twierdzenie. Zbieżność metody Gaussa-Seidela**

Jeśli macierz A jest diagonalnie dominująca, to metoda Gaussa–Seidela jest zbieżna do x^* dla dowolnego punktu startowego x_0.

Metoda Gaussa-Seidela III

- *Uwagi*
  - Obie metody, Jacobiego i (zwłaszcza) Gaussa–Seidela znajdują zastosowanie w prostych algorytmach rozwiązywania układów równań nieliniowych.
  - Zaletą tych algorytmów jest to, że głównym składnikiem iteracji jest rozwiązywanie skalarnego równania nieliniowego na każdym kroku metody.
  - Metoda Gaussa–Seidela jest w wielu przypadkach rzeczywiście szybciej zbieżna od metody Jacobiego, np. w przypadku macierzy jednowymiarowego laplasjanu. Jednak wciąż jej zbieżność jest zbyt wolna, by stosować ją jako samodzielną metodę rozwiązania dla tego zadania.

Metoda SOR

- Czy można poprawić/przyspieszyć zbieżność metody Gaussa–Seidela?
- Wprowadza się parametr relaksacji ω
- I kolejne współrzędne nowego przybliżenia x_{k+1} wyznacza się przez kombinację poprzedniego przybliżenia $x_i^{(k)}$ i współrzędną nowego przybliżenia $\tilde{x}_i^{k+1}$, otrzymaną metodą Gaussa–Seidela:

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega\tilde{x}_i^{k+1} \tag{34}$$

- Jeśli $\omega = 1$, dostajemy z powrotem metodę Gaussa–Seidela
- Zwykle wybiera się $\omega > 1$ i metodę nazywa się metodą *nadrelaksacji* (ang. successive overrelaxation, SOR)
  - Metoda jest "najlepszą" metodą stacjonarną
  - Rozkład macierzy $A = M - Z$, odpowiadający metodzie SOR z parametrem ω jest zdefiniowany jako:

$$M = \frac{1}{\omega}D + L, \qquad Z = \left(\frac{1}{\omega} - 1\right)D - U \tag{35}$$

- Można pokazać twierdzenie Ostrowskiego i Reicha
  - Jeśli $A = A^T > 0$, to metoda SOR jest zbieżna dla dowolnego $\omega \in (0, 2)$

Klasyczna metoda iteracyjna/Metoda Richardsona

- Klasyczna metoda iteracyjna
  - Niech
$$M = I, \quad N = I - A$$
  - skąd otrzymujemy:
$$x^{(k+1)} = (I - A)x^{(k)} + b$$
- Metoda Richardsona
  - Podstawienie
$$M = I, \quad N = I - A$$
    jak dla klasycznej metody iteracji.
  - i dodatkowo wprowadzamy parametr relaksacji τ:
$$x^{(k+1)} = x^{(k)} + \tau(b - Ax^k)$$
  - Uwagi
    - ★ Jeśli A jest nieokreślona, to dla żadnego τ metoda Richardsona nie jest zbieżna do x^* dla dowolnego x_0
    - ★ Jeśli A jest dodatnio określona, to metoda Richardsona jest zbieżna dla $0 < \tau < 2/\lambda_{\max}(A)$, a wartość optymalna τ jest równa:
$$\tau_{\text{opt}} = \frac{2}{\lambda_{\max}(A) + \lambda_{\min}(A)}$$
      gdzie $\lambda_{\max}(A)$ i $\lambda_{\min}(A)$ to, odpowiednio, największa i najmniejsza wartość własna macierzy A

Metody projekcji

Wstęp

- Dotychczas omówione metody opierają się na czysto formalnym, mechanicznym podziale macierzy, bezpośrednio związanym z jej strukturą
- Można zdefiniować metody iteracyjne o podobnym koszcie iteracji, ale w których kolejne przybliżenia rozwiązania wybierane są tak, by zminimalizować błąd
- Idea: metodę iteracyjną definiujemy w formie aktualizacji poprzedniego przybliżenia:

$$x_{k+1} = x_k + \delta_k \tag{36}$$

- Najlepsza poprawka δ_k, oznaczona jako δ^*, powinna spełniać równanie

$$A\delta^* = r_k \tag{37}$$

  i wtedy otrzymalibyśmy $x_{k+1} = x^*$
- Problem: wyznaczenie poprawki wymaga rozwiązania tego samego układu równań, tylko z nieco inną prawą stroną, ale nie ma to znaczenia ze względu na sam problem — i wracamy do punktu wyjścia
- Nowy pomysł: rozwiążmy układ równań (37) w przybliżeniu, jakąś tanią metodą i w ten sposób określmy iteracyjną, zbieżną metodę

Metody projekcji - konstrukcja rozwiązania I

- Określenie przybliżonego rozwiązania równania poprawki:

$$A\delta^* = r_k \tag{38}$$

wymaga innegi sformułowania problemu

- Niech dwie macierze, U i V, mają tę własność, że kolumny każdej z nich tworzą bazę $\mathbb{R}^n$. Wtedy rozwiązanie dokładne równania najlepszej poprawki, δ^*, można reprezentować w bazie V:

$$\delta^* = Va^*$$

dla pewnego $a^* \in \mathbb{R}^n$
Ponadto, z nieosobliwości macierzy U i V wynika, że:

$$A\delta^* = r_k \iff U^T AVa^* = U^T r_k$$

Metody projekcji - konstrukcja rozwiązania II

- W ten sposób możemy zdefiniować *przybliżoną* najlepszą poprawkę: niech U_k i V_k będą macierzami pełnego rzędu, tego samego, zadanego z góry, rozmiaru równego $n \times d_k$, wtedy poprawkę $delta_k$ określamy jako wektor:

$$\delta_k = V_k a_k$$

taki, że $a_k \in \mathbb{R}^{d_k}$ spełnia równanie:

$$U_k^T A V_k a_k = U_k^T r_k \tag{39}$$

Jest to właśnie *metoda projekcji*

Metody projekcji - analiza I

- Macierz zredukowana $A_k = U_k^T A V_k$ jest kwadratowa, rozmiaru d_k, stąd δ_k będzie tanie do wyznaczenia, gdy d_k jest niewielkie
- Nazwa metody bierze się stąd, że wektor residualny równania poprawki, $r_k - A\delta_k$ jest prostopadły do podprzestrzeni rozpiętej przez kolumny U_k:

$$U_k^T (r_k - A\delta_k) = 0$$

- Z drugiej strony, δ_k będzie dobrze określone tylko wtedy, gdy macierz zredukowana A_k będzie nieosobliwa
  - Nie zawsze musi to być prawdą, nawet jeśli A jest nieosobliwa, np.

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad U_k = V_k = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

- Dla gwarancji odwracalności macierzy zredukowanej, wybiera się najczęściej macierz pełnego rzędu V_k i w zależności od własności macierzy A dobiera się macierz U_k w następujący sposób:
  - Jeżeli $A = A^T > 0$, to bierzemy $U_k = V_k$; wtedy macierz zredukowana $A_k = V_k^T A V_k$ jest symetryczna i dodatnio określona

Metody projekcji - analiza II

- Jeśli A jest tylko nieosobliwa, to bierzemy $U_k = AV_k$, macierz zredukowana jest postaci $A_k = V_k^T A^T A V_k$, więc jest macierzą zredukowaną poprzedniego rodzaju, ale dla macierzy równań normalnych, $A^T A$

- Z powyższej analizy wynika, że metody projekcji są metodami minimalizacji (wektora residuum)

Metoda najszybszego spadku I

- Klasycznym przykładem metody projekcji jest metoda najszybszego spadku
- Założenie: macierz A jest symetryczna i dodatnio określona
- W tej metodzie definiujemy

$$U_k = V_k = r_k = b - Ax_k$$

- W tym przypadku Wymiar przestrzeni rozpiętej przez kolumny U_k jest równy $d_k = 1$, stąd równanie poprawki upraszcza się do jednego równania skalarnego na $a_k \in \mathbb{R}$:

$$a_k = \frac{r_k^T r_k}{r_k^T A r_k}$$

i w konsekwencji:

$$x_{k+1} = x_k + a_k r_k$$

Metoda najszybszego spadku II

- Nazwa metody wywodzi się stąd, że wektor poprawki jest proporcjonalny do residuum, które z kolei jest kierunkiem gradientu funkcjonału:

$$\phi(x) = \|x^* - x\|_A^2$$

w punkcie x_k:

$$\nabla\phi(x_k) = b - Ax_k = r_k$$

- Można pokazać, że zbieżność w metodzie najszybszego spadku jest równa:

$$\|x^* - x_{k+1}\|_A \leq \frac{\kappa - 1}{\kappa + 1}\|x^* - x_k\|_A$$

gdzie $\kappa = \mathrm{cond}_2(A) = \lambda_{\max}(A)/\lambda_{\min}(A)$.

Metoda najmniejszego residuum I

- Jeżeli o macierzy A wiemy jedynie, że jest nieosobliwa, można zastosować metodę najmniejszego residuum
- W tej metodzie wybieramy:

$$V_k = r_k = b - Ax_k \qquad U_k = AV_k = Ar_k$$

- Równanie poprawki znów upraszcza się do jednego równania skalarnego na $a_k \in \mathbb{R}$:

$$a_k = \frac{r_k^T A^T r_k}{r_k^T A^T A r_k}$$

i w konsekwencji:

$$x_{k+1} = x_k + a_k r_k$$

- Zbieżność metody. Można pokazać, że jeżeli macierz $A_{\text{sym}} = (A + A^T)/2$ jest dodatnio określona i oznaczmy $\mu = \lambda_{\min}(A_{\text{sym}}) > 0$, to:

$$\|r_{k+1}\|_2 \leq \left(1 - \frac{\mu^2}{\|A\|_2^2}\right)^{1/2} \|r_k\|_2$$

A_{sym} nazywana jest *częścią symetryczną* macierzy A

Przykłady

Zadanie 1 I

- Założenia. Niech B macierz kwadratowa $n \times n$, o losowych wartościach, która ma średnio 10 elementów niezerowych w wierszu (współczynnik wypełnienia jest równy $10/n$)
- Niech macierz A będzie postaci

$$A = B + pI$$

gdzie I to macierz jednostkowa, wartość p, w zależności od wartości wyrazów macierzy B pozwala na określenie jak bardzo macierz A będzie diagonalnie dominująca (można tak dobrać p, żeby A była diagonalnie dominująca)

- Zadanie
  - Sprawdź w eksperymencie obliczeniowym, jak stopień dominacji diagonali wpływa na szybkość zbieżności metody Jacobiego $\Rightarrow$ dobierz różne wartości parametru p
  - Dla porównania sprawdź, jak z macierzą A poradzi sobie metoda bezpośrednia: oparta na rozkładzie LU macierzy A

Zadanie 1 II

- Uwaga
  - ⋆ Testy przeprowadź dla macierzy rozmiaru $n = 2500$
  - ⋆ Sprawdź, jak zmieni się czas obliczeń gdy n będzie jeszcze większe; która metoda: iteracyjna, czy bezpośrednia, zagwarantuje prawidłowy wynik w krótszym czasie?
  - ⋆ Sprawdź, czy jest sens używać metody iteracyjnej, jeśli rozmiar macierzy jest niewielki, np. $n = 100$
  - ⋆ Sprawdź, dla jakiego n warto zastosować metodę iteracyjną ze względu na czas działania

Zadanie 2

- Dana jest macierz A postaci:

$$A = \begin{pmatrix} 1 & \alpha & \alpha \\ \alpha & 1 & \alpha \\ \alpha & \alpha & \alpha \end{pmatrix}$$

- Pokaż, że:
  - $A > 0 \iff -1 < 2\alpha < 2$
  - Metoda Jacobiego dla tej macierzy jest zbieżna, wtedy i tylko wtedy, gdy $-1 < 2\alpha < 1$
- Czy wniosek o zbieżności metody Jacobiego można uogólnić na przypadek, gdy A, rozmiaru $n \times n$, ma na diagonali same jedynki, a poza nią wszystkie jej elementy są równe α?

Przypomnienie z algebry

Wektory i wartości własne I

- Niech A będzie macierzą kwadratową $n \times n$
  - Wtedy A wyznacza przekształcenie liniowe przestrzeni $\mathbb{R}^n$ w siebie
- Niech $v \in \mathbb{R}^n$ będzie niezerowym wektorem i niech $L = \{t \cdot v : t \in \mathbb{R}\}$ będzie prostą wyznaczoną przez ten wektor
- **Definicja**. Jeżeli przekształcenie A przekształca prostą L w siebie, to mówimy, że v jest *wektorem własnym* przekształcenia A:

$$A \cdot v = \lambda \cdot v$$

dla pewnej liczby rzeczywistej λ, zwanej *wartością własną* związaną z wektorem własnym v

- Jeżeli v jest wektorem własnym macierzy A o wartości własnej λ, to:

$$A \cdot v - \lambda \cdot v = 0$$

Równanie to można zapisać w postaci:

$$(A - \lambda \cdot I) \cdot v = 0 \tag{40}$$

Niech A_λ oznacza macierz $A - \lambda \cdot I$, która powstaje z macierzy A przez odjęcie wartości λ na przekątnej

Wektory i wartości własne II

- Równanie (40) mówi, że $A_\lambda \cdot v = 0$, tzn., v leży w jądrze A_λ. Ponieważ z założenia $v \neq 0$, to A_λ nie jest różnowartościowe, więc nie jest bijekcją. Stąd wynika, że $\det A_\lambda = 0$, tzn., że A_λ jest macierzą zdegenerowaną.
- Funkcję $w_A(\lambda) = \det A_\lambda$ nazywamy *wielomianem charakterystycznym* macierzy A.